

Klasifikasi Penyakit Gigi Berdasarkan Citra Panoramik Menggunakan GoogleNet Inception-V3

Raditia Riandi¹, Dara Cantika Dewi², Marshanda Putri P³, Kanaya Dea T⁴, Ryantoni⁵

¹ Institut Teknologi Sumatera, Indonesia.

² Institut Teknologi Sumatera, Indonesia

³ Institut Teknologi Sumatera, Indonesia

⁴ Institut Teknologi Sumatera, Indonesia

⁵ Institut Teknologi Sumatera, Indonesia

Corresponding author's e-mail: raditia.121450105@student.itera.ac.id

ABSTRACT

Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi otomatis untuk penyakit gigi berdasarkan citra panoramik dengan menggunakan model GoogleNet Inception-V3. Citra panoramik gigi adalah alat diagnostik yang penting di bidang kedokteran gigi, memungkinkan identifikasi kondisi seperti Bone Density Changes-Bone Destruction Regions (BDC-BDR), karies, dan gigi sehat. Dalam penelitian ini, digunakan dataset yang terdiri dari 232 gambar radiografi, yang kemudian dibagi menjadi tiga kategori untuk analisis. Proses pengolahan data meliputi eksplorasi data, normalisasi, augmentasi, dan evaluasi model melalui matriks kebingungan (Confusion Matrix). Hasil penelitian menunjukkan bahwa model Inception-V3 berhasil mencapai akurasi pelatihan sebesar 96,30% dan akurasi testing sebesar 97,59%. Hasil ini menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam mengenali dan mengklasifikasikan citra gigi secara otomatis. Dengan demikian, penelitian ini memberikan kontribusi signifikan terhadap penerapan teknologi deep learning dalam diagnostik penyakit gigi di Indonesia, berpotensi meningkatkan efisiensi dan akurasi dalam proses diagnosis.

Keywords:

Citra panoramik gigi, Googlenet Inception-V3, klasifikasi penyakit gigi, Diagnostik kedokteran gigi

Pendahuluan

Citra panoramik gigi merupakan teknik pencitraan medis yang umum digunakan dalam bidang kedokteran gigi untuk mendeteksi berbagai kondisi kesehatan gigi dan mulut, seperti BDC-BDR, karies, dan gigi sehat [1]. Teknik ini menawarkan gambaran menyeluruh dari struktur gigi, tulang rahang, serta jaringan sekitarnya, sehingga sangat membantu tenaga medis dalam diagnosis dan perencanaan perawatan [2]. Berdasarkan data Riset Kesehatan Dasar Indonesia tahun 2018, 45,3% penyakit gigi dan mulut adalah karies, yang diikuti oleh berbagai kondisi lain seperti abses gingiva sebesar 14%. Data ini menunjukkan bahwa penyakit-penyakit tersebut dapat diidentifikasi melalui citra panoramik, sehingga membuka peluang penelitian yang lebih luas [3]. Proses diagnosis penyakit gigi secara manual oleh tenaga medis memiliki keterbatasan berupa subjektivitas dan ketergantungan pada keterampilan individu, terutama di wilayah dengan akses terbatas terhadap tenaga ahli [5]. Dalam beberapa tahun terakhir, teknologi *deep learning*, khususnya *Convolutional Neural Networks* (CNN), telah berkembang pesat dan mampu meningkatkan efisiensi serta akurasi dalam analisis citra medis. Studi sebelumnya menunjukkan keberhasilan penerapan Inception-v3 untuk mengidentifikasi penyakit kanker kulit berjenis Melanoma dengan persentase akurasi sebesar 99.93% dan penyakit kanker kulit berjenis Basal


Cell Carcinoma (BCC) dengan persentase akurasi sebesar 92.26% [6]. Melanjutkan perkembangan pada model tersebut, penelitian ini akan fokus pada klasifikasi BDC-BDR, karies, dan gigi sehat menggunakan model Inception-V3. Model ini dikenal mampu mengenali pola fitur kompleks dalam citra visual dengan sangat baik, berkat arsitekturnya yang mendalam dan efisien. Tantangan utama dalam penelitian ini adalah variasi kualitas citra, keanekaragaman struktur gigi, serta tumpang tindih jaringan yang dapat mempengaruhi performa model. Dengan melakukan evaluasi menyeluruh terhadap model *Inception V3*, penelitian ini bertujuan untuk mengembangkan sistem klasifikasi yang lebih akurat dan andal. Hasil penelitian ini diharapkan dapat berkontribusi pada perkembangan teknologi *deep learning* di bidang kesehatan, khususnya dalam mendiagnosis penyakit gigi seperti BDC-BDR, karies, dan gigi sehat melalui citra panoramik secara otomatis. Sistem ini diharapkan mampu meningkatkan efisiensi, kecepatan, dan akurasi dalam diagnosis penyakit gigi di Indonesia.

Metode

Pada penelitian ini, klasifikasi penyakit gigi berdasarkan citra panoramik akan dilakukan menggunakan pendekatan *Googlenet Inception-V3*, yang merupakan salah satu metode pembelajaran mendalam yang unggul serta efektif untuk pemrosesan citra. *Google Inception-V3* ini dipilih karena arsitektur ini memiliki kemampuan yang efektif dalam mendeteksi pola yang cukup kompleks pada citra medis

Deskripsi Data

Penelitian ini menggunakan dataset radiografi gigi panoramik yang terdiri dari 232 gambar, diperoleh dari jurnal "*A Comprehensive Dental Dataset of Six Classes for Deep Learning Based Object Detection Study*" oleh Rubaba Binte Rahman et al., yang diterbitkan di *ScienceDirect*. Dataset ini tersedia di platform Mendeley melalui tautan <https://data.mendeley.com/datasets/c4hhrkxytw/4>. Dataset ini mencakup enam kondisi gigi, yaitu gigi sehat, karies, gigi yang terkena impaksi, infeksi, gigi retak, dan akar gigi rusak [7]. Namun, penelitian ini hanya menggunakan tiga kondisi, yaitu gigi sehat, karies, dan kondisi *Bone Density Changes-Bone Destruction Regions* (BDC-BDR). Dataset ini digunakan untuk melatih model dengan arsitektur *Inception-V3*, yang dirancang untuk mengklasifikasikan tiga kondisi gigi berdasarkan citra panoramik. Data dan contoh gambar yang digunakan dalam penelitian ini dapat dilihat pada Gambar 1.




Gambar 1. Dataset (Sebelah kiri kelas BDC-BDR), (Tengah kelas *Caries*),
(Kanan kelas *Healthy Teeth*)

CNN

CNN (*Convolutional Neural Network*) adalah salah satu metode *deep learning* yang dirancang untuk memproses, mengenali, dan mengekstraksi fitur dari data berupa gambar atau objek. CNN merupakan salah satu jenis *Artificial Neural Network* (ANN) yang mengandalkan *convolutional layer* sebagai lapisan utamanya, tetapi juga dapat mencakup lapisan lain, seperti *pooling layer* dan *fully connected layer*, untuk membangun struktur CNN yang mendalam. Proses kerja CNN melibatkan beberapa tahapan struktur, seperti konvolusi, fungsi aktivasi, dan *pooling*. Proses ini dilakukan berulang kali dengan konvolusi dan *pooling* yang dilakukan beberapa kali. Selanjutnya, dilakukan lapisan *fully connected*, dan akhirnya dilakukan proses pelatihan [8]. CNN


dapat memproses serta mengekstrak fitur dari data gambar yang akan diklasifikasikan. Berikut arsitektur dari CNN yang dapat dilihat pada Gambar 2.



Gambar 2. Arsitektur CNN [9]

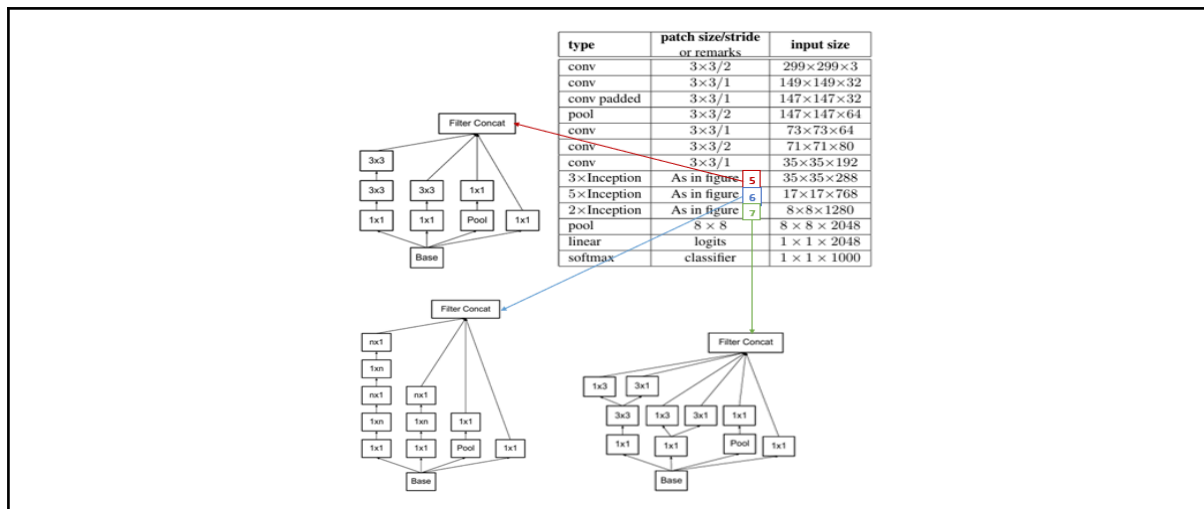
Inception V3

Inception-V3 adalah sebuah arsitektur *deep convolutional* yang merupakan pengembangan dari model GoogleNet atau Inception-v1, yang telah diperbarui melalui dua perubahan nama dan pengembangan arsitektur. Perubahan tersebut mencakup penambahan *batch normalization* (BN) serta faktorisasi tambahan pada tahap konvolusi untuk mengurangi jumlah koneksi atau parameter tanpa mengurangi efektivitas jaringan yang digunakan [10]. Arsitektur ini kemudian dinamakan *Inception-V3* yang dapat dilihat pada Gambar 3. sebagai berikut:



Gambar 3. Arsitektur Inception-V3 [11]

Model Inception-V3 ini digunakan untuk ekstraksi fitur gambar, dengan ukuran *input* gambar yang dapat diterima sebesar 299 x 299 x 3 piksel. Untuk proses ekstraksi fitur, lapisan klasifikasi atau lapisan terakhir dari model dihapus, karena penelitian ini tidak mencakup proses klasifikasi. Konfigurasi arsitektur Inception-V3 dapat dilihat pada Gambar 4.



Gambar 4. Konfigurasi Arsitektur Inception-V3 [12]

Tahapan Penelitian

1. EDA

Exploratory Data Analysis dalam penelitian ini dilakukan untuk mengecek bagaimana persebaran datanya di setiap label, yang setelah itu dilakukan pengecekan data duplikat dari setiap file apakah data dari setiap file ada yang terdistribusi pada data file lain juga atau tidak, jika hasil dari EDA ini didapatkan bahwa adanya data duplikat maka data akan dihapus dari class yang memiliki label minoritas. Hal ini bertujuan agar pada saat pelatihan model nantinya, model dapat memahami setiap data dengan baik tanpa adanya kebingungan yang disebabkan data yang mempunyai label ganda.

2. Preprocessing Data

Pada penelitian ini, *preprocessing* data dilakukan menggunakan dataset radiografi gigi *panoramic*. Beberapa langkah pada *preprocessing* sebagai berikut :

- Duplikasi Data

Setelah dilakukan proses EDA, ditemukan adanya data duplikasi dalam dataset yang digunakan. Keberadaan data duplikat ini perlu diatasi untuk menjaga kualitas dan validitas hasil analisis. Berdasarkan hasil analisis, jumlah data duplikat yang teridentifikasi pada masing-masing kelas yaitu BDC-BDR: 0, *Caries*: 31, *Fractured Teeth*: 11, *Healthy Teeth*: 134, *Impacted Teeth*: 86, dan *Infection*: 23.

Untuk mengatasi hal ini, dilakukan proses penghapusan data duplikat sehingga hanya data unik yang digunakan dalam penelitian. Setelah proses penghapusan selesai, data yang dapat digunakan berasal dari folder BDC-BDR, *Caries*, dan *Healthy Teeth*. Hal ini dilakukan untuk memastikan analisis lebih akurat dan representatif terhadap data sebenarnya.

- Normalisasi

Langkah selanjutnya melakukan *resize* atau mengubah ukuran piksel gambar menjadi 299 x 299. Ukuran ini dipilih untuk menyesuaikan dengan format *input* yang disarankan oleh model Inception V3. Proses *resize* ini bertujuan untuk mengurangi beban memori selama pemrosesan gambar *panoramic* sekaligus memastikan konsistensi ukuran *input* pada seluruh dataset yang akan dianalisis. Dengan demikian, model dapat memproses data secara lebih efisien dan seragam.

Selanjutnya, dilakukan proses normalisasi terhadap nilai piksel pada gambar. Normalisasi dilakukan dengan membagi setiap nilai piksel pada dataset dengan 255.0, sehingga rentang nilai piksel berada dalam skala [0, 1]. Proses normalisasi ini diterapkan pada dataset latih (*train_data*) dan testing (*data_valid*) menggunakan fungsi *map*, yang memproses setiap pasangan data (*image*, *label*) secara efisien.

3. Split Data

Dataset yang akan digunakan dilakukan pemisahan antara data *train* (latih) dan juga data *testing* (uji) ini bertujuan untuk melatih model Inception-v3 menggunakan data latih dan menguji hasil pembelajaran model melalui data uji [13]. Split data dilakukan dengan rasio 90:10 dengan 90% data latih dan 10% data uji.

4. Data Augmentasi

Augmentasi data merupakan salah satu solusi untuk mengatasi keterbatasan jumlah dataset. Dalam konteks pembelajaran mesin, augmentasi digunakan untuk memperluas variasi data dan meningkatkan kualitas dataset dengan menciptakan variasi baru dari dataset radiografi panoramik yang digunakan [14]. Dalam penelitian ini, augmentasi data diterapkan menggunakan *ImageDataGenerator* untuk meningkatkan variasi dan kualitas dataset. Beberapa transformasi yang digunakan termasuk rotasi gambar hingga 30 derajat, pergeseran horizontal dan vertikal hingga 20%, distorsi sudut gambar (*shear*) hingga 20%, zoom hingga 20%, serta pembalikan gambar secara horizontal. Piksel yang kosong akibat transformasi diisi dengan metode interpolasi nearest neighbor. Proses ini menghasilkan 13 variasi gambar untuk setiap gambar asli, sehingga dataset latih yang awalnya berjumlah 229 gambar menjadi 2.977 gambar setelah augmentasi. Augmentasi ini bertujuan untuk memperkaya data dan meningkatkan kemampuan model dalam melakukan generalisasi.

5. Modelling

Arsitektur yang digunakan dalam CNN pada penelitian ini adalah *Inception-V3*, yang merupakan salah satu varian dari keluarga *Inception Network*. Model ini dirancang untuk mengatasi permasalahan efisiensi komputasi pada pelatihan *deep learning* dengan memproses data gambar secara optimal melalui konsep *factorized convolutions* dan penggunaan *parallel convolutional layers*. Inception-V3 membagi operasi konvolusi yang kompleks menjadi beberapa operasi konvolusi yang lebih kecil, sehingga mengurangi jumlah parameter dan mempercepat proses komputasi. Selain itu, arsitektur ini menggunakan teknik *dimension reduction* dan *auxiliary classifiers* untuk meningkatkan akurasi serta mencegah *overfitting* selama pelatihan [11].

6. Model Fit

Proses pelatihan model dilakukan menggunakan fungsi *model.fit* dengan memanfaatkan data augmentasi dan beberapa *callback* untuk meningkatkan performa pelatihan. Data augmentasi diterapkan melalui generator *datagen.flow*, yang menghasilkan *batch* data secara dinamis dengan ukuran *batch_size* sebesar 16. Jumlah *epoch* ditetapkan sebanyak 15 untuk menghindari *overfitting* dan mengoptimalkan waktu pelatihan. Selain itu, digunakan dua *callback* utama, yaitu *early stopping* untuk menghentikan pelatihan secara otomatis jika performa testing tidak meningkat, dan *learning rate scheduler (lr_scheduler)* untuk menyesuaikan laju pembelajaran selama pelatihan. Data testing (*val_x*, *val_y*) digunakan untuk mengevaluasi performa model pada setiap *epoch*. Proses ini memastikan model terlatih secara optimal dengan memanfaatkan augmentasi data dan pengaturan hyperparameter yang adaptif.

7. Evaluasi Model

Pada penelitian ini, evaluasi model menggunakan *Confusion matrix*, yang berisi informasi tentang klasifikasi aktual dan prediksi oleh klasifikasi sistem. Performa sistem biasanya dievaluasi menggunakan data dalam matriks [12]. Dalam *confusion matrix*, setiap kolom berisi nilai yang mewakili *instance* di kelas yang diprediksi, sedangkan setiap baris berisi nilai yang mewakili *instance* di kelas sebenarnya. *Confusion matrix* mencakup empat istilah utama yaitu *true positive*, *true negative*, *false positive*, dan *false negative*, yang digunakan untuk mengevaluasi kinerja klasifikasi. Selanjutnya, metrik kinerja yang dihitung untuk

klasifikasi biner meliputi akurasi, presisi, *recall*, dan *F1-Score*. Untuk klasifikasi multi kelas, yang dihitung adalah akurasi, rata-rata makro presisi, recall, dan *F1-Score*.

- *Accuracy*

Accuracy adalah metrik evaluasi yang mengukur seberapa sering prediksi model benar secara keseluruhan. Nilai *accuracy* dihitung sebagai perbandingan jumlah prediksi yang benar terhadap total data yang diuji.

$$Accuracy = \frac{Jumlah\ Prediksi\ Benar}{Total\ Jumlah\ Data} \quad (1)$$

- *Precision*

Precision mengukur proporsi prediksi positif yang benar terhadap semua prediksi positif yang dibuat oleh model.

$$Precision = \frac{True\ Positive\ (TP)}{True\ Positive\ (TP) + False\ Positive\ (FP)} \quad (2)$$

- *Recall*

Recall, atau dikenal juga sebagai *Sensitivity* atau *True Positive Rate* (TPR), mengukur sejauh mana model dapat menemukan semua *instance* positif dari dataset. *Recall* menunjukkan kemampuan model dalam mendeteksi kelas positif.

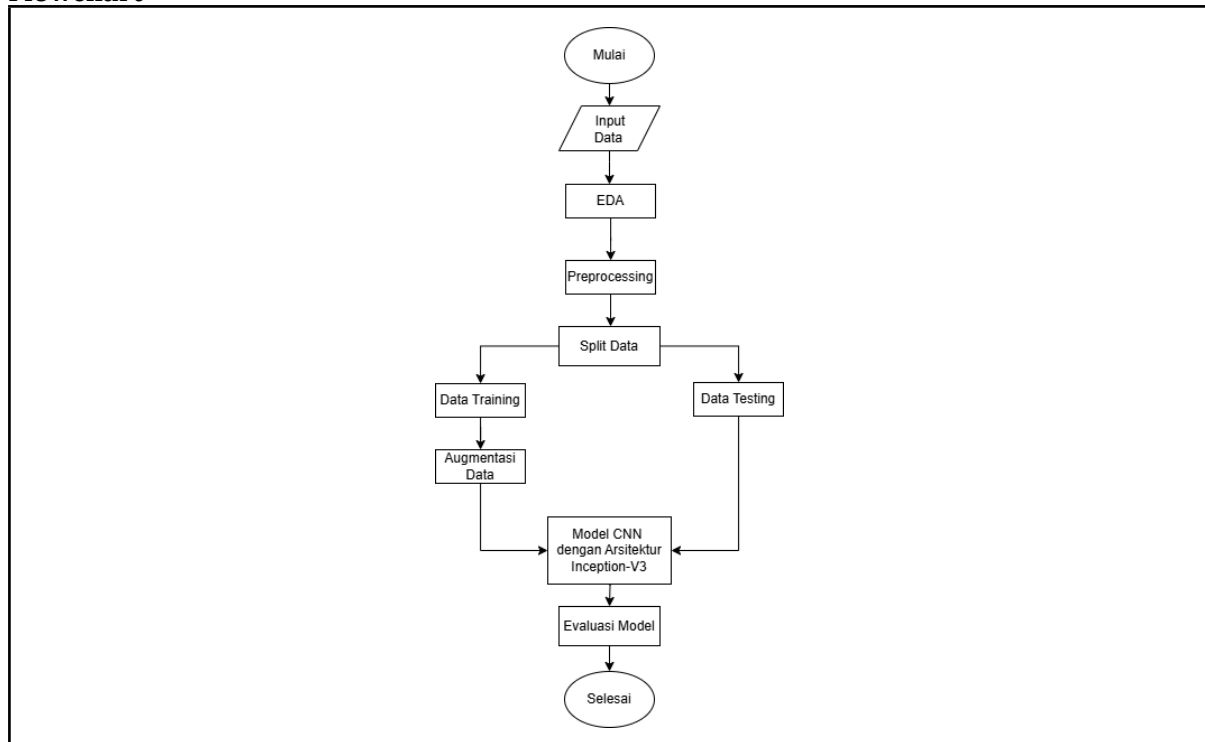
$$Recall = \frac{True\ Positive\ (TP)}{True\ Positive\ (TP) + False\ Negative\ (FN)} \quad (3)$$

- *F1-Score*

F1-Score adalah rata-rata harmonis antara *precision* dan *recall*. Metrik ini berguna ketika terdapat ketidakseimbangan kelas pada dataset karena menggabungkan kedua metrik tersebut menjadi satu nilai.

$$F1-Score = 2 \frac{Precision \times Recall}{Precision + Recall} \quad (4)$$

Flowchart



Gambar 5. Flowchart Penelitian

Hasil dan Pembahasan

Exploratory Data Analysis (EDA)

Seperti yang telah dijelaskan sebelumnya, data yang digunakan dalam penelitian ini adalah data Dental OPG *X-ray* pada tahun 2024 dikumpulkan dari tiga klinik gigi berbeda., yang diolah kembali sesuai dengan penelitian yang diterapkan, dataset ini berukuran total 197MB, yang sudah mencakup semua gambar dan label yang telah diolah, Berikut adalah jabaran lengkap mengenai data yang telah diolah kembali:

- Folder Deteksi Objek : Berisi 232 gambar asli
- Folder Klasifikasi Dataset : Berisi data untuk tugas klasifikasi berdasarkan kategori penyakit

Tabel 1 di bawah ini merupakan hasil dari proses pengecekan dan penghapusan data duplikat pada citra gigi panoramik. Data awal yang dikumpulkan terdiri dari:

- *Healthy Teeth*: 223 gambar
- *Caries*: 119 gambar
- BCDE/BDR: 52 gambar

Setelah dilakukan proses pengecekan duplikasi, ditemukan bahwa:

- *Healthy Teeth* memiliki 134 duplikat, sehingga data unik yang digunakan hanya 89 gambar.
- *Caries* memiliki 88 gambar yang bersih dari duplikat.
- BCDE/BDR tidak memiliki duplikat (0 duplikat), sehingga jumlah datanya tetap 52 gambar.



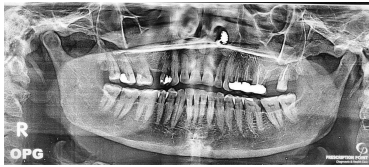



Tabel 1. Dataset setelah penghapusan duplikat

No	Kelas	Jumlah Gambar
1	BCDE/BDR	52
2	Caries	88
3	Healthy Teeth	89

Normalisasi Data

Pada tahapan ini dilakukan *resize* atau mengubah ukuran piksel gambar menjadi 299 x 299 sebagai bagian dari *preprocessing* untuk menyesuaikan dengan format input yang disarankan oleh model Inception V3, dengan hasil sebelum dan sesudah normalisasi sebagai berikut :

Tabel 2. Hasil Normalisasi Gambar

Klasifikasi	Gambar rontgen sebelum resize	Gambar rontgen sesudah resize
Gigi Berpenyakit BCDE/BDR		
Gigi Berpenyakit Caries		
Gigi tidak berpenyakit Healthy Teeth		

setelah dilakukan *resize* menjadi pixel 299 x 299 tersendiri lalu dilakukan normalisasi data agar memiliki nilai pada rentang [0, 1] pada masing masing data, baik pada data latih(*train_data*) dan juga data testing (*data_valid*).

Data Augmentasi

Tahapan augmentasi meliputi beberapa bagian yang dilakukan pada tiap *image* data, agar model dapat membaca dari berbagai bentuk atau kondisi pada gambar sehingga lebih flexible dalam mempelajari pola gambar saat melakukan augmentasi. Augmentasi pada penelitian ini sendiri hanya dilakukan pada data latih (*train_data*) setelah dilakukan pembagian sebanyak 90:10 untuk data latih dan data testingnya. Setelah dilakukan augmentasi, data yang berawal jumladhnya 232 gambar panoramc menjadi 604 gambar hasil augmentasi beserta label nya dan hanya dilakukan untuk data latih (*train_data*) banyaknya data yang dihasilkan dari proses augmentasi bergantung pada iterasi yang dilakukan.

Pemodelan Data


Pelatihan model dilakukan selama 40 epoch menggunakan *Inception V3* sebagai model dasar dengan konfigurasi hyperparameter yang bervariasi. Parameter utama yang digunakan meliputi *batch size* dan *optimizer* Adam. Hasil pelatihan menunjukkan nilai *train accuracy* dan *validation accuracy* yang berbeda pada setiap konfigurasi. Pada konfigurasi pertama dengan *batch size* 16, model mencapai *train accuracy* sebesar 96.30% dan *validation accuracy* sebesar 97.59%. Pada konfigurasi kedua dengan *batch size* 32, *train accuracy* tercatat 92.07%, sementara *validation accuracy* menurun menjadi 85.02%. Sementara itu, pada konfigurasi terakhir dengan *batch size* 64, *train accuracy* tercatat sebesar 84.12% dan *validation accuracy* sebesar 82.61%.

Tabel 3. Akurasi *Train* dan testing (*Batch Size*)

Hyperparameter		Optimizer	Train Accuracy	Vall Accuracy
Epoch	Batch Size			
40	16	Adam	96.30	97.59
40	32	Adam	92.07	85.02
40	64	Adam	84.12	82.61

Pengujian Model

Pengujian model dilakukan untuk mengklasifikasikan penyakit gigi berdasarkan citra panoramik. Tahapan pengujian diawali dengan mengunggah gambar uji, yang kemudian diproses dengan menyesuaikan ukuran gambar menjadi 299 x 299 piksel serta mempertahankan mode warna RGB. Selanjutnya, gambar tersebut diubah ke dalam format array dan dinormalisasi dengan membagi setiap nilai piksel dengan 255 untuk memastikan skala data berada dalam rentang 0 hingga 1. Proses prediksi dilakukan menggunakan model *GoogleNet Inception V3* yang telah dilatih sebelumnya. Hasil prediksi kemudian ditampilkan dalam bentuk label kelas, yang menunjukkan jenis penyakit gigi berdasarkan analisis citra panoramik.



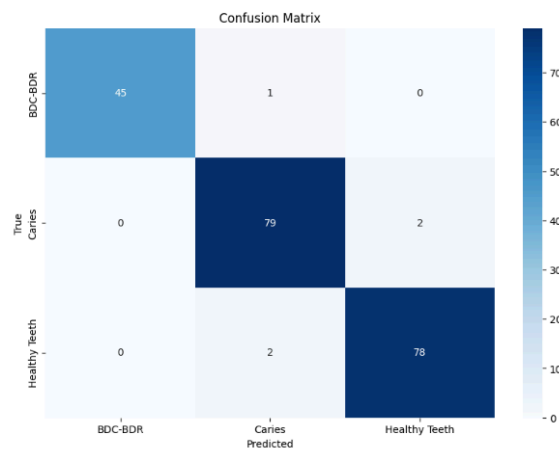
Gambar 6. Gambar grafik *training* dan *validation accuracy* dan *Loss* untuk *batch size* 16

Gambar 6 diatas memuat grafik untuk hasil *Training* dan *Validation* untuk *Accuracy* dan *Loss*, dapat dilihat pada grafik akurasi pada saat training awal dimulai pada range (epoch 0-10) akurasi pada data train dan validation meningkat tajam mengindikasikan model melakukan pembelajaran dengan sangat cepat pada tahap awal, dan ketika setelah pada masa tersebut akurasi pada data training cukup stabil namun berbeda dengan akurasi data validation yang

berfluktuasi mengindikasikan adanya pergerakan yang sedikit overfitting setelah *epoch* ke 10. Akurasi namun terus meningkat hingga mendekati nilai yang cukup tinggi yaitu range 95%-97% dengan performa yang baik. Pada grafik Loss model banyak melakukan pembelajaran terhadap data yang diindikasikan dari penurunan Loss yang cukup signifikan menandakan bahwa model berhasil dalam meminimalkan kesalahan prediksi, tidak ada peningkatan signifikan pada *validation Loss* yang menandakan model tidak mengalami underfitting dan melakukan hasil akurasi yang signifikan.

Evaluasi Model

Confusion matrix memberikan hasil dari evaluasi klasifikasi dari confusion matrix setelah hasil dari prediksi model terhadap 3 kelas yaitu BDC-BDR, Caries, dan Healthy Teeth



Gambar 7. Confusion matrix model batch size 16

Angka pada matriks gambar 7 di atas, mengindikasikan untuk masing masing hasil prediksi. Berdasarkan hasil evaluasi diatas terdapat 45 sampel yang berhasil memprediksi dengan benar (True Positive), sementara 1 sampel yang salah diprediksi sebagai kelas Karies dan tidak ada sampel yang memprediksi sebagai kelas *Healthy Teeth*. Kelas Karies ada sebanyak 79 sampel yang berhasil diprediksi dengan benar sedangkan 2 sampel salah diprediksi sebagai *Healthy Teeth* dan tidak ada sampel yang diprediksi sebagai BDC-BDR. Selanjutnya, untuk kelas *Healthy Teeth*, sebanyak 78 sampel berhasil diprediksi dengan benar, sementara 2 sampel salah diprediksi sebagai Karies, dan tidak ada sampel yang diprediksi sebagai BDC-BDR. Sehingga didapatkan perhitungan matriks evaluasi sebagai berikut :

Tabel 4. Matriks Evaluasi

Matriks Evaluasi	Batch Size 16		
	BDC/BDR	Caries	Healthy Teeth
Precision	100%	96%	97%
Recall	98%	98%	97%
F1-Score	99%	97%	97%
Support	46%	81%	80%

Berdasarkan hasil matriks evaluasi yang ditampilkan pada Tabel 4, model memberikan hasil yang sangat baik sebesar 98% pada dataset, Nilai *precision* BDC-BDR sendiri menghasilkan nilai

yang sempurna sementara *Caries* dan *Healthy Teeth* dengan precision 0.96-0.97. *Recall* sendiri menghasilkan suatu nilai pada kelas BDC-BDR dan *Caries* dengan nilai 0.98, sedangkan *Healthy Teeth* mencapai 0.97 mengindikasikan hasil dari kinerja model yang cukup baik. Nilai *F1-Score* di semua kelas berkisar antara 0.97–0.99, yang mencerminkan keseimbangan *precision* dan *recall*. Secara keseluruhan, nilai *macro average* dan *weighted average* konsisten tinggi, menggambarkan performa yang stabil di semua kelas. Dengan hanya 5 kesalahan prediksi pada confusion matrix, model ini dapat diandalkan untuk mendeteksi BDC-BDR, *Caries*, dan *Healthy Teeth* dengan tingkat akurasi dan kinerja yang optimal.

Kesimpulan

Model klasifikasi Inception V3 menunjukkan performa sangat baik dalam mendeteksi penyakit gigi dari citra panoramik dengan akurasi 98%. Kelas BDC-BDR memiliki precision sempurna (100%), sementara *Caries* dan *Healthy Teeth* mencapai precision dan recall di kisaran 96%-98%. Nilai *F1-Score* yang stabil antara 97%-99% mencerminkan keseimbangan precision dan recall. Dari 207 sampel, hanya terjadi 5 kesalahan prediksi. Proses preprocessing, normalisasi, dan augmentasi data berhasil meningkatkan performa model tanpa indikasi underfitting. Dan secara keseluruhan memiliki akurasi pelatihan sebesar 96,30% dan akurasi testing sebesar 97,59%, Dengan hasil ini, model dapat diandalkan untuk mendeteksi BDC-BDR, *Caries*, dan *Healthy Teeth* secara akurat.

Daftar Pustaka

- [1] D. R. Bella, Perbandingan Kualitas Citra Radiograf Panoramik Antara Metode Konvensional dan Digital Indirect di RSGM Prof. Soedomo Kajian pada Radiograf Pasien Periode Gigi Bercampur, Dissertation, Universitas Gadjah Mada, 2018.
- [2] N. Nurmaifah, "Pencitraan Ortropantomografi dan Cone Beam Computed Tomography dalam Mengklasifikasi Impaksi Gigi Kaninus Rahang Atas= Orthopantomography and Cone Beam Computed Tomography Imaging in Classification of Impacted Maxillary Canines", Dissertation, Universitas Hasanuddin, 2023.
- [3] J. D. Adam and J. E. Ratuela, "Tingkat pengetahuan tentang kebersihan gigi dan mulut siswa sekolah dasar," *Indonesian Journal of Public Health and Community Medicine*, vol. 3, no. 1, pp. 001-007, 2022.
- [4] F. S. Santoso, "Penerapan Teknologi Pengolahan Citra Digital dalam Deteksi Dini Penyakit Melalui Citra Medis," *Jurnal Teknologi Terkini*, vol. 3, no. 7, 2023.
- [5] B. A. Sukarno and A. F. Rozi, "Sistem Pakar Diagnosa Penyakit Gigi dan Mulut Menggunakan Metode Certainty Factor," *Journal of Information System and Artificial Intelligence*, vol. 1, no. 2, pp. 61-69, 2021.
- [6] K. Kosman, A. Widyadhana, Y. Wahyuningsih, and F. Mahendrasusila, "Pengujian Metode Inception V3 dalam Mengidentifikasi Penyakit Kanker Kulit," *Jurnal Teknologi Informatika dan Komputer*, vol. 10, no. 1, pp. 132-142, 2024.
- [7] R. B. Rahman, et al., "A comprehensive dental dataset of six classes for deep learning based object detection study," *Data in Brief*, vol. 57, p. 110970, 2024.
- [8] U. Ungkawa and G. A. L. I. H. Al Hakim, "Klasifikasi Warna pada Kematangan Buah Kopi Kuning menggunakan Metode CNN Inception V3," *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, vol. 11, no. 3, pp. 731, 2023.
- [9] R. Yohannes and M. E. A. Rivan, "Klasifikasi Jenis Kanker Kulit Menggunakan CNN-SVM," *Jurnal Algoritme*, vol. 2, no. 2, pp. 133-144, 2022.
- [10] S. B. Bapat, "GoogleNet: A Deep Dive into Google's Neural Network Technology," Medium, [Online]. Available: <https://medium.com/@siddheshb008/googlenet-a-deep-dive-into-googles-neural-network-technology-f588d1b49e55>. [Accessed: Dec. 17, 2024].
- [11] C. Szegedy, et al., "Rethinking the inception architecture for computer vision," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 2818-2826.
- [12] C. Szegedy, et al., "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2818-2826, 2016.
- [13] A. Ridhovan and A. Suharso, "Penerapan Metode Residual Network (RESNET) Dalam Klasifikasi Penyakit Pada Daun Gandum," *JUPI (Jurnal Ilmiah Penelitian dan Pembelajaran Informatika)*, vol. 7, no. 1, pp. 58-65, 2022.
- [14] B. M. Sujatmiko, E. Yudaningsiyas, and P. M. Raharjo, "Convolution Neural Network dengan Desain Jaringan ResNet sebagai Metode Klasifikasi Tumor Kulit," *Jurnal Simantec*, vol. 11, no. 1, pp. 53-64, 2022.